# 收藏 | Pytorch小抄宝典!

人工智能算法与Python大数据 Today



### 人工智能算法与Python大数据

致力于提供深度学习、机器学习、人工智能干货文章,为AI人员提供学习路线以及前沿... 23篇原创内容

Official Account

#### 点上方**人工智能算法与Python大数据**获取更多干货

在右上方 … 设为星标 ★,第一时间获取资源

仅做学术分享,如有侵权,联系删除

转载于:作者:科技猛兽

https://zhuanlan.zhihu.com/p/205407928

#### 一、基本配置

# 导入包和版本查询:

```
import torch
import torch.nn as nn
import torchvision
print(torch.__version__)
print(torch.version.cuda)#cuda版本查询
print(torch.backends.cudnn.version())#cudnn版本查询
print(torch.cuda.get_device_name(0))#设备名
```

### 可复现性

在硬件设备(CPU、GPU)不同时,完全的可复现性无法保证,即使随机种子相同。但是,在同一个设备上,应该保证可复现性。具体做法是,在程序开始的时候**固定torch的随机种子**,同时也把 numpy的随机种子固定。

np.random.seed(0)

```
torch.manual_seed(0) #为CPU设置种子用于生成随机数,以使得结果是确定的
torch.cuda.manual_seed_all(0) #为所有的GPU设置种子,以使得结果是确定的
torch.backends.cudnn.deterministic = True
torch.backends.cudnn.benchmark = False
```

解释一下: torch.backends.cudnn.benchmark = true

总的来说,大部分情况下,设置这个 flag 可以让内置的 cuDNN 的 auto-tuner 自动寻找最适合当前配置的**高效算法**,来达到优化运行效率的问题。

#### 一般来讲,应该遵循以下准则:

- 如果网络的输入数据维度或类型上变化不大,设置 torch.backends.cudnn.benchmark = true 可 以增加运行效率;
- 如果网络的输入数据在每次 iteration 都变化的话,会导致 cnDNN 每次都会去寻找一遍最优配置,这样反而会降低运行效率。

torch.backends.cudnn.deterministic 是啥?顾名思义,将这个 flag 置为True的话,每次返回的卷积算法将是确定的,即默认算法。如果配合上设置 Torch 的随机种子为固定值的话,应该可以保证每次运行网络的时候相同输入的输出是固定的。

### 显卡设置

如果只需要一张显卡:

```
# Device configuration
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
```

如果需要指定多张显卡,比如0,1号显卡:

```
import os
os.environ['CUDA_VISIBLE_DEVICES'] = '0,1'
```

也可以在命令行运行代码时设置显卡:

CUDA\_VISIBLE\_DEVICES=0,1 python train.py

清除显存

torch.cuda.empty\_cache()

也可以使用在命令行重置GPU的指令

nvidia-smi --gpu-reset -i [gpu\_id]

二、张量(Tensor)处理

# 张量的数据类型

PyTorch有9种CPU张量类型和9种GPU张量类型。

Data type	dtype	CPU tensor	GPU tensor
32-bit floating point	torch.float32 or torch.float	torch.FloatTensor	torch.cuda.FloatTensor
64-bit floating point	torch.float64 or torch.double	torch.DoubleTensor	torch.cuda.DoubleTensor
16-bit floating point	torch.float16 or torch.half	torch.HalfTensor	torch.cuda.HalfTensor
8-bit integer (unsigned)	torch.uint8	torch.ByteTensor	torch.cuda.ByteTensor
8-bit integer (signed)	torch.int8	torch.CharTensor	torch.cuda.CharTensor
16-bit integer (signed)	torch.int16 Or torch.short	torch.ShortTensor	torch.cuda.ShortTensor
32-bit integer (signed)	torch.int32 Or torch.int	torch.IntTensor	torch.cuda.IntTensor
64-bit integer (signed)	torch.int64 Or torch.long	torch.LongTensor	torch.cuda.LongTensor
Boolean	torch.bool	torch.BoolTensor	torch.cuda.BoolTensor

# 张量基本信息

```
tensor = torch.randn(3,4,5)
print(tensor.type()) # 数据类型
print(tensor.size()) # 张量的shape,是个元组
print(tensor.dim()) # 维度的数量
```

# 命名张量

张量命名是一个非常有用的方法,这样可以方便地使用维度的名字来做索引或其他操作,大大提高了可读性、易用性,防止出错。

```
# 在PyTorch 1.3之前,需要使用注释
```

```
# Tensor[N, C, H, W]
```

images = torch.randn(32, 3, 56, 56)

```
images.sum(dim=1)
images.select(dim=1, index=0)

# PyTorch 1.3之后

NCHW = ['N', 'C', 'H', 'W']
images = torch.randn(32, 3, 56, 56, names=NCHW)
images.sum('C')
images.select('C', index=0)

# 也可以这么设置

tensor = torch.rand(3,4,1,2,names=('C', 'N', 'H', 'W'))
# 使用align_to可以对维度方便地排序

tensor = tensor.align_to('N', 'C', 'H', 'W')
```

### 数据类型转换

```
# 设置默认类型,pytorch中的FloatTensor远远快于DoubleTensor
torch.set_default_tensor_type(torch.FloatTensor)

# 类型转换
tensor = tensor.cuda()
tensor = tensor.cpu()
tensor = tensor.float()
tensor = tensor.long()
```

# torch.Tensor与np.ndarray转换

除了CharTensor,其他所有CPU上的张量都支持转换为numpy格式然后再转换回来。

```
ndarray = tensor.cpu().numpy()
tensor = torch.from_numpy(ndarray).float()
tensor = torch.from_numpy(ndarray.copy()).float() # If ndarray has negative stride.
```

# Torch.tensor与PIL.Image转换

# pytorch中的张量默认采用[N, C, H, W]的顺序,并且数据范围在[0,1],需要进行转置和规范化

```
# torch.Tensor -> PIL.Image
image = PIL.Image.fromarray(torch.clamp(tensor*255, min=0, max=255).byte().permute(1,2)
image = torchvision.transforms.functional.to_pil_image(tensor) # Equivalently way

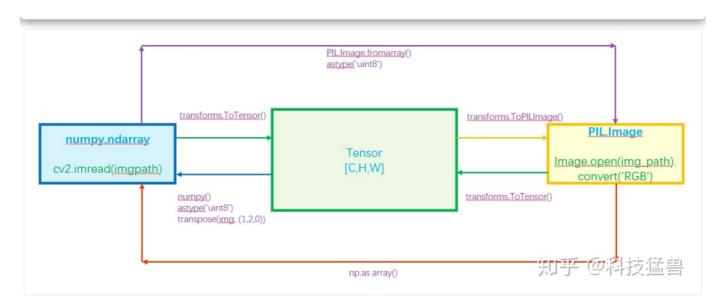
# PIL.Image -> torch.Tensor
path = r'./figure.jpg'
tensor = torch.from_numpy(np.asarray(PIL.Image.open(path))).permute(2,0,1).float() / 2
tensor = torchvision.transforms.functional.to_tensor(PIL.Image.open(path)) # Equivalen
```

#### 对应的2种方法的示意图分别为:

torch.clamp 把每个元素夹紧到区间 [min, max] 中。第1种方法用到的2个函数是:PIL.lmage.fromarray() torch.from\_numpy(np.asarray())

# np.ndarray与PIL.Image的转换

```
image = PIL.Image.fromarray(ndarray.astype(np.uint8))
ndarray = np.asarray(PIL.Image.open(path))
```



# 从只包含一个元素的张量中提取值

```
value = torch.rand(1).item()
```

### 张量形变

```
# 在将卷积层输入全连接层的情况下通常需要对张量做形变处理,
```

```
# 相比torch.view, torch.reshape可以自动处理输入张量不连续的情况。
```

```
tensor = torch.rand(2,3,4)
shape = (6, 4)
tensor = torch.reshape(tensor, shape)
```

### 打乱顺序

```
tensor = tensor[torch.randperm(tensor.size(0))] # 打乱第一个维度
```

# 水平翻转

```
# pytorch不支持tensor[::-1]这样的负步长操作,水平翻转可以通过张量索引实现
```

# 假设张量的维度为[N, D, H, W].

```
tensor = tensor[:,:,:,torch.arange(tensor.size(3) - 1, -1, -1).long()]
```

#### 复制张量

#### 张量拼接

. . .

注意torch.cat和torch.stack的区别在于torch.cat沿着给定的维度拼接,

而torch.stack会新增一维。例如当参数是3个10x5的张量,torch.cat的结果是30x5的张量,

而torch.stack的结果是3x10x5的张量。

. . .

```
tensor = torch.cat(list_of_tensors, dim=0)
tensor = torch.stack(list_of_tensors, dim=0)
```

# 将整数标签转为one-hot编码

```
# pytorch的标记默认从0开始

tensor = torch.tensor([0, 2, 1, 3])

N = tensor.size(0)

num_classes = 4

one_hot = torch.zeros(N, num_classes).long()

one_hot.scatter_(dim=1, index=torch.unsqueeze(tensor, dim=1), src=torch.ones(N, num_classes)
```

### 得到非零元素

```
torch.nonzero(tensor)  # index of non-zero elements
torch.nonzero(tensor==0)  # index of zero elements
torch.nonzero(tensor).size(0)  # number of non-zero elements
torch.nonzero(tensor == 0).size(0)  # number of zero elements
```

# 判断两个张量相等

```
torch.allclose(tensor1, tensor2) # float tensor
torch.equal(tensor1, tensor2) # int tensor
```

#### 张量扩展

```
# Expand tensor of shape 64*512 to shape 64*512*7*7.
tensor = torch.rand(64,512)
torch.reshape(tensor, (64, 512, 1, 1)).expand(64, 512, 7, 7)
```

# 矩阵乘法

```
# Matrix multiplcation: (m*n) * (n*p) * -> (m*p).
result = torch.mm(tensor1, tensor2)
```

```
# Batch matrix multiplication: (b*m*n) * (b*n*p) -> (b*m*p)
result = torch.bmm(tensor1, tensor2)

# Element-wise multiplication.
result = tensor1 * tensor2
```

### 计算两组数据之间的两两欧式距离

利用broadcast机制

```
dist = torch.sqrt(torch.sum((X1[:,None,:] - X2) ** 2, dim=2))
```

#### 三、模型定义和操作

#### 一个简单两层卷积网络的示例

```
# convolutional neural network (2 convolutional layers)
class ConvNet(nn.Module):
   def __init__(self, num_classes=10):
        super(ConvNet, self).__init__()
        self.layer1 = nn.Sequential(
            nn.Conv2d(1, 16, kernel_size=5, stride=1, padding=2),
            nn.BatchNorm2d(16),
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=2, stride=2))
        self.layer2 = nn.Sequential(
            nn.Conv2d(16, 32, kernel size=5, stride=1, padding=2),
            nn.BatchNorm2d(32),
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=2, stride=2))
        self.fc = nn.Linear(7*7*32, num_classes)
   def forward(self, x):
        out = self.layer1(x)
        out = self.layer2(out)
        out = out.reshape(out.size(0), -1)
        out = self.fc(out)
```

return out

```
model = ConvNet(num_classes).to(device)
```

### 双线性汇合 (bilinear pooling)

```
X = torch.reshape(N, D, H * W)  # Assume X has shape N*D*H*W
X = torch.bmm(X, torch.transpose(X, 1, 2)) / (H * W) # Bilinear pooling
assert X.size() == (N, D, D)
X = torch.reshape(X, (N, D * D))
X = torch.sign(X) * torch.sqrt(torch.abs(X) + 1e-5) # Signed-sqrt normalization
X = torch.nn.functional.normalize(X) # L2 normalization
```

### 多卡同步 BN(Batch normalization)

当使用 torch.nn.DataParallel 将代码运行在多张 GPU 卡上时,PyTorch 的 BN 层默认操作是各卡上数据独立地计算均值和标准差,同步 BN 使用所有卡上的数据一起计算 BN 层的均值和标准差,缓解了当批量大小(batch size)比较小时对均值和标准差估计不准的情况,是在目标检测等任务中一个有效的提升性能的技巧。

### 将已有网络的所有BN层改为同步BN层

```
sync_bn.running_var = module.running_var

if module.affine:
    sync_bn.weight = module.weight.clone().detach()
    sync_bn.bias = module.bias.clone().detach()

return sync_bn

else:
    for name, child_module in module.named_children():
        setattr(module, name) = convert_syncbn_model(child_module, process_group=p)
    return module
```

affine定义了BN层的参数γ和β是否是可学习的(不可学习默认是常数1和0)。

### 类似 BN 滑动平均

如果要实现类似 BN 滑动平均的操作,在 forward 函数中要使用原地(inplace)操作给滑动平均赋值。

# 计算模型整体参数量

```
num parameters = sum(torch.numel(parameter) for parameter in model.parameters())
```

### 查看网络中的参数

可以通过model.state\_dict()或者model.named\_parameters()函数查看现在的全部可训练参数(包括通过继承得到的父类中的参数)

```
params = list(model.named_parameters())
(name, param) = params[28]
print(name)
print(param.grad)
print('-----')
(name2, param2) = params[29]
print(name2)
print(param2.grad)
print('-----')
(name1, param1) = params[30]
print(name1)
print(param1.grad)
```

# 模型权重初始化

注意 model.modules() 和 model.children() 的区别:model.modules() 会迭代地遍历模型的所有子层,而 model.children() 只会遍历模型下的一层。

```
# Common practise for initialization.
for layer in model.modules():
   if isinstance(layer, torch.nn.Conv2d):
        torch.nn.init.kaiming_normal_(layer.weight, mode='fan_out',
                                      nonlinearity='relu')
        if layer.bias is not None:
            torch.nn.init.constant (layer.bias, val=0.0)
   elif isinstance(layer, torch.nn.BatchNorm2d):
        torch.nn.init.constant_(layer.weight, val=1.0)
        torch.nn.init.constant_(layer.bias, val=0.0)
   elif isinstance(layer, torch.nn.Linear):
        torch.nn.init.xavier normal (layer.weight)
        if layer.bias is not None:
            torch.nn.init.constant_(layer.bias, val=0.0)
# Initialization with given tensor.
layer.weight = torch.nn.Parameter(tensor)
```

### 提取模型中的某一层

modules()会返回模型中所有模块的迭代器,它能够访问到最内层,比如self.layer1.conv1这个模块,还有一个与它们相对应的是name\_children()属性以及named\_modules(),这两个不仅会返回模块的迭代器,还会返回网络层的名字。

```
# 取模型中的前两层

new_model = nn.Sequential(*list(model.children())[:2]

# 如果希望提取出模型中的所有卷积层,可以像下面这样操作:

for layer in model.named_modules():
    if isinstance(layer[1],nn.Conv2d):
        conv_model.add_module(layer[0],layer[1])
```

### 部分层使用预训练模型

注意如果保存的模型是 torch.nn.DataParallel,则当前的模型也需要是

```
model.load_state_dict(torch.load('model.pth'), strict=False)
```

### 将在 GPU 保存的模型加载到 CPU

```
model.load_state_dict(torch.load('model.pth', map_location='cpu'))
```

### 导入另一个模型的相同部分到新的模型

模型导入参数时,如果两个模型结构不一致,则直接导入参数会报错。用下面方法可以把另一个模型的相同的部分导入到新的模型中。

```
# model_new代表新的模型
# model_saved代表其他模型,比如用torch.load导入的已保存的模型
model_new_dict = model_new.state_dict()
model_common_dict = {k:v for k, v in model_saved.items() if k in model_new_dict.keys()
model_new_dict.update(model_common_dict)
model_new.load_state_dict(model_new_dict)
```

# 计算数据集的均值和标准差

```
import os
import cv2
import numpy as np
from torch.utils.data import Dataset
from PIL import Image
def compute_mean_and_std(dataset):
    # 输入PyTorch的dataset,输出均值和标准差
    mean_r = 0
    mean_g = 0
    mean_b = 0
    for img, _ in dataset:
        img = np.asarray(img) # change PIL Image to numpy array
        mean_b += np.mean(img[:, :, 0])
       mean_g += np.mean(img[:, :, 1])
        mean_r += np.mean(img[:, :, 2])
    mean_b /= len(dataset)
    mean g /= len(dataset)
    mean_r /= len(dataset)
    diff r = 0
    diff g = 0
    diff b = 0
    N = 0
    for img, _ in dataset:
        img = np.asarray(img)
        diff_b += np.sum(np.power(img[:, :, 0] - mean_b, 2))
        diff_g += np.sum(np.power(img[:, :, 1] - mean_g, 2))
        diff_r += np.sum(np.power(img[:, :, 2] - mean_r, 2))
```

```
N += np.prod(img[:, :, 0].shape)

std_b = np.sqrt(diff_b / N)

std_g = np.sqrt(diff_g / N)

std_r = np.sqrt(diff_r / N)

mean = (mean_b.item() / 255.0, mean_g.item() / 255.0, mean_r.item() / 255.0)

std = (std_b.item() / 255.0, std_g.item() / 255.0, std_r.item() / 255.0)

return mean, std
```

### 常用训练和验证数据预处理

其中 ToTensor 操作会将 PIL.Image 或形状为 H×W×D,数值范围为 [0, 255] 的 np.ndarray 转换为 形状为 D×H×W,数值范围为 [0.0, 1.0] 的 torch.Tensor。

#### 五、模型训练和测试

#### 分类模型训练代码

```
# Loss and optimizer
```

```
criterion = nn.CrossEntropyLoss()
optimizer = torch.optim.Adam(model.parameters(), lr=learning_rate)
# Train the model
total_step = len(train_loader)
for epoch in range(num_epochs):
    for i ,(images, labels) in enumerate(train_loader):
        images = images.to(device)
        labels = labels.to(device)
        # Forward pass
        outputs = model(images)
        loss = criterion(outputs, labels)
        # Backward and optimizer
        optimizer.zero_grad()
        loss.backward()
        optimizer.step()
        if (i+1) % 100 == 0:
            print('Epoch: [{}/{}], Step: [{}/{}], Loss: {}'
                  .format(epoch+1, num_epochs, i+1, total_step, loss.item()))
```

#### 分类模型测试代码

```
print('Test accuracy of the model on the 10000 test images: {} %'
    .format(100 * correct / total))
```

#### 自定义loss

继承torch.nn.Module类写自己的loss。

```
class MyLoss(torch.nn.Module):
    def __init__(self):
        super(MyLoss, self).__init__()

    def forward(self, x, y):
        loss = torch.mean((x - y) ** 2)
        return loss
```

# 标签平滑(label smoothing)

写一个label\_smoothing.py的文件,然后在训练代码里引用,用LSR代替交叉熵损失即可。label\_smoothing.py内容如下:

```
import torch
import torch.nn as nn

class LSR(nn.Module):

    def __init__(self, e=0.1, reduction='mean'):
        super().__init__()

        self.log_softmax = nn.LogSoftmax(dim=1)
        self.e = e
        self.reduction = reduction

def _one_hot(self, labels, classes, value=1):
        """
```

Convert labels to one hot vectors

```
Args:
        labels: torch tensor in format [label1, label2, label3, ...]
        classes: int, number of classes
        value: label value in one hot vector, default to 1
    Returns:
        return one hot format labels in shape [batchsize, classes]
    one_hot = torch.zeros(labels.size(0), classes)
    #labels and value_added size must match
    labels = labels.view(labels.size(0), -1)
    value_added = torch.Tensor(labels.size(0), 1).fill_(value)
    value added = value added.to(labels.device)
    one hot = one hot.to(labels.device)
    one_hot.scatter_add_(1, labels, value_added)
    return one_hot
def _smooth_label(self, target, length, smooth_factor):
    """convert targets to one-hot format, and smooth
    them.
    Args:
        target: target in form with [label1, label2, label_batchsize]
        length: length of one-hot format(number of classes)
        smooth_factor: smooth factor for label smooth
    Returns:
        smoothed labels in one hot format
    one hot = self. one hot(target, length, value=1 - smooth factor)
    one hot += smooth factor / (length - 1)
    return one hot.to(target.device)
```

```
def forward(self, x, target):
    if x.size(0) != target.size(0):
        raise ValueError('Expected input batchsize ({}) to match target batch_size
                .format(x.size(0), target.size(0)))
    if x.dim() < 2:
        raise ValueError('Expected input tensor to have least 2 dimensions(got {})
                .format(x.size(0)))
    if x.dim() != 2:
        raise ValueError('Only 2 dimension tensor are implemented, (got {})'
                .format(x.size()))
    smoothed_target = self._smooth_label(target, x.size(1), self.e)
    x = self.log_softmax(x)
    loss = torch.sum(- x * smoothed_target, dim=1)
    if self.reduction == 'none':
        return loss
    elif self.reduction == 'sum':
        return torch.sum(loss)
    elif self.reduction == 'mean':
        return torch.mean(loss)
    else:
        raise ValueError('unrecognized option, expect reduction to be one of none,
```

### 或者直接在训练文件里做label smoothing

```
for images, labels in train_loader:
   images, labels = images.cuda(), labels.cuda()
   N = labels.size(0)
   # C is the number of classes.
   smoothed labels = torch.full(size=(N, C), fill value=0.1 / (C - 1)).cuda()
```

```
smoothed_labels.scatter_(dim=1, index=torch.unsqueeze(labels, dim=1), value=0.9)

score = model(images)

log_prob = torch.nn.functional.log_softmax(score, dim=1)

loss = -torch.sum(log_prob * smoothed_labels) / N

optimizer.zero_grad()

loss.backward()

optimizer.step()
```

## Mixup训练

### L1 正则化

```
l1_regularization = torch.nn.L1Loss(reduction='sum')
loss = ... # Standard cross-entropy loss
for param in model.parameters():
    loss += torch.sum(torch.abs(param))
loss.backward()
```

### 不对偏置项进行权重衰减(weight decay)

pytorch里的weight decay相当于I2正则

#### 得到当前学习率

```
# If there is one global learning rate (which is the common case).
lr = next(iter(optimizer.param_groups))['lr']

# If there are multiple learning rates for different layers.
all_lr = []
for param_group in optimizer.param_groups:
    all_lr.append(param_group['lr'])
```

另一种方法,在一个batch训练代码里,当前的Ir是optimizer.param\_groups[0]['Ir']

### 学习率衰减

```
# Reduce learning rate when validation accuarcy plateau.
scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(optimizer, mode='max', patience:
for t in range(0, 80):
    train(...)
    val(...)
    scheduler.step(val_acc)

# Cosine annealing learning rate.
scheduler = torch.optim.lr_scheduler.CosineAnnealingLR(optimizer, T_max=80)
# Reduce learning rate by 10 at given epochs.
scheduler = torch.optim.lr_scheduler.MultiStepLR(optimizer, milestones=[50, 70], gamma:
for t in range(0, 80):
```

```
scheduler.step()
  train(...)
  val(...)

# Learning rate warmup by 10 epochs.
scheduler = torch.optim.lr_scheduler.LambdaLR(optimizer, lr_lambda=lambda t: t / 10)
for t in range(0, 10):
  scheduler.step()
  train(...)
  val(...)
```

### 优化器链式更新

从1.4版本开始,torch.optim.lr\_scheduler 支持链式更新(chaining),即用户可以定义两个schedulers,并交替在训练中使用。

```
import torch
from torch.optim import SGD
from torch.optim.lr_scheduler import ExponentialLR, StepLR
model = [torch.nn.Parameter(torch.randn(2, 2, requires_grad=True))]
optimizer = SGD(model, 0.1)
scheduler1 = ExponentialLR(optimizer, gamma=0.9)
scheduler2 = StepLR(optimizer, step_size=3, gamma=0.1)
for epoch in range(4):
    print(epoch, scheduler2.get_lr()[0])
    optimizer.step()
    scheduler1.step()
    scheduler2.step()
```

## 模型训练可视化

PyTorch可以使用tensorboard来可视化训练过程。

安装和运行TensorBoard。

```
pip install tensorboard
  tensorboard --logdir=runs
https://mp.weixin.qq.com/s/hANAvGaJLLJ3YN5a-P4rEA
```

使用SummaryWriter类来收集和可视化相应的数据,放了方便查看,可以使用不同的文件夹,比如'Loss/train'和'Loss/test'。

```
from torch.utils.tensorboard import SummaryWriter
import numpy as np

writer = SummaryWriter()

for n_iter in range(100):
    writer.add_scalar('Loss/train', np.random.random(), n_iter)
    writer.add_scalar('Loss/test', np.random.random(), n_iter)
    writer.add_scalar('Accuracy/train', np.random.random(), n_iter)
    writer.add_scalar('Accuracy/test', np.random.random(), n_iter)
    writer.add_scalar('Accuracy/test', np.random.random(), n_iter)
```

### 保存与加载断点

注意为了能够恢复训练,我们需要同时保存模型和优化器的状态,以及当前的训练轮数。

```
start_epoch = 0

# Load checkpoint.

if resume: # resume为参数,第一次训练时设为0,中断再训练时设为1

model_path = os.path.join('model', 'best_checkpoint.pth.tar')

assert os.path.isfile(model_path)

checkpoint = torch.load(model_path)

best_acc = checkpoint['best_acc']

start_epoch = checkpoint['epoch']

model.load_state_dict(checkpoint['model'])

optimizer.load_state_dict(checkpoint['optimizer'])

print('Load checkpoint at epoch {}.'.format(start_epoch))

print('Best accuracy so far {}.'.format(best_acc))

# Train the model

for epoch in range(start_epoch, num_epochs):

...

# Test the model
```

```
# save checkpoint
is_best = current_acc > best_acc
best_acc = max(current_acc, best_acc)
checkpoint = {
    'best_acc': best_acc,
    'epoch': epoch + 1,
    'model': model.state_dict(),
    'optimizer': optimizer.state_dict(),
}
model_path = os.path.join('model', 'checkpoint.pth.tar')
best_model_path = os.path.join('model', 'best_checkpoint.pth.tar')
torch.save(checkpoint, model_path)
if is_best:
    shutil.copy(model_path, best_model_path)
```

### 提取 ImageNet 预训练模型某层的卷积特征

# 提取 ImageNet 预训练模型多层的卷积特征

```
class FeatureExtractor(torch.nn.Module):
    """Helper class to extract several convolution features from the given
   pre-trained model.
   Attributes:
        _model, torch.nn.Module.
        _layers_to_extract, list<str> or set<str>
   Example:
       >>> model = torchvision.models.resnet152(pretrained=True)
        >>> model = torch.nn.Sequential(collections.OrderedDict(
                list(model.named_children())[:-1]))
        >>> conv_representation = FeatureExtractor(
                pretrained model=model,
                layers_to_extract={'layer1', 'layer2', 'layer3', 'layer4'})(image)
    0.00
   def __init__(self, pretrained_model, layers_to_extract):
        torch.nn.Module.__init__(self)
        self. model = pretrained model
        self._model.eval()
        self._layers_to_extract = set(layers_to_extract)
   def forward(self, x):
        with torch.no_grad():
            conv_representation = []
            for name, layer in self._model.named_children():
                x = layer(x)
                if name in self._layers_to_extract:
                    conv_representation.append(x)
            return conv_representation
```

### 微调全连接层

```
model = torchvision.models.resnet18(pretrained=True)
for param in model.parameters():
    param.requires_grad = False
model.fc = nn.Linear(512, 100) # Replace the last fc layer
optimizer = torch.optim.SGD(model.fc.parameters(), lr=1e-2, momentum=0.9, weight_decays)
```

### 以较大学习率微调全连接层,较小学习率微调卷积层

#### 六、其他注意事项

- 不要使用太大的线性层。因为nn.Linear(m,n)使用的是O(m,n)的内存,线性层太大很容易超出现有显存。
- 不要在太长的序列上使用RNN。因为RNN反向传播使用的是BPTT算法,其需要的内存和输入序列的长度呈线性关系。
- model(x) 前用 model.train() 和 model.eval() 切换网络状态。
- 不需要计算梯度的代码块用 with torch.no\_grad() 包含起来。
- model.eval() 和 torch.no\_grad() 的区别在于,model.eval() 是将网络切换为测试状态,例如 BN 和dropout在训练和测试阶段使用不同的计算方法。torch.no\_grad() 是关闭 PyTorch 张量的自动求导机制,以减少存储使用和加速计算,得到的结果无法进行 loss.backward()。
- model.zero\_grad()会把整个模型的参数的梯度都归零,而optimizer.zero\_grad()只会把传入其中的参数的梯度归零。
- torch.nn.CrossEntropyLoss 的输入不需要经过 Softmax。torch.nn.CrossEntropyLoss 等价于 torch.nn.functional.log\_softmax + torch.nn.NLLLoss。
- loss.backward() 前用 optimizer.zero\_grad() 清除累积梯度。
- torch.utils.data.DataLoader 中尽量设置 pin\_memory=True,对特别小的数据集如 MNIST 设置 pin\_memory=False 反而更快一些。num\_workers 的设置需要在实验中找到最快的取值。
- 用 del 及时删除不用的中间变量,节约 GPU 存储。
- 使用 inplace 操作可节约 GPU 存储,如

```
x = torch.nn.functional.relu(x, inplace=True)
```

• 减少 CPU 和 GPU 之间的数据传输。 例如如果你想知道一个 epoch 中每个 mini-batch 的 loss 和准确率,先将它们累积在 GPU 中等一个 epoch 结束之后一起传输回 CPU 会比每个 mini-batch 都进行一次 GPU 到 CPU 的传输更快。

- 使用半精度浮点数 half() 会有一定的速度提升,具体效率依赖于 GPU 型号。需要小心数值精度 过低带来的稳定性问题。
- 时常使用 assert tensor.size() == (N, D, H, W) 作为调试手段,确保张量维度和你设想中一致。
- 除了标记 y 外,**尽量少使用一维张量,使用 n\*1 的二维张量代替**,可以避免一些意想不到的一维 张量计算结果。
- 统计代码各部分耗时

• 使用TorchSnooper来调试PyTorch代码,程序在执行的时候,就会自动 print 出来每一行的执行 结果的 tensor 的形状、数据类型、设备、是否需要梯度的信息。

```
# pip install torchsnooper
import torchsnooper

# 对于函数,使用修饰器
@torchsnooper.snoop()

# 如果不是函数,使用 with 语句来激活 TorchSnooper, 把训练的那个循环装进 with 语句中去。
with torchsnooper.snoop():
原本的代
```

-----♥-----

声明:本内容来源网络,版权属于原作者 图片来源网络,不代表本公众号立场。如有侵权,联系删除

AI博士私人微信,还有少量空位